



UNIVERSIDAD DE CHILE
FACULTAD DE CIENCIAS FÍSICAS Y MATEMÁTICAS
ESCUELA DE POSTGRADO Y EDUCACIÓN CONTINUA
DEPARTAMENTO DE INGENIERÍA MATEMÁTICA

**PREDICCIÓN DE ELECCIÓN DE RUTA EN REDES DE TRANSPORTE
PÚBLICO CON MACHINE LEARNING: EVIDENCIA DESDE DATOS
MASIVOS DEL SISTEMA RED DE SANTIAGO**

TESIS PARA OPTAR AL GRADO DE MAGÍSTER EN CIENCIA DE DATOS

MEMORIA PARA OPTAR AL TÍTULO DE INGENIERO CIVIL MATEMÁTICO

SEBASTIÁN GONZALO ACUÑA URZÚA

PROFESOR GUÍA:
EDUARDO GRAELLS-GARRIDO

PROFESORES CO-GUÍA:
JACQUELINE ARRIAGADA FERNÁNDEZ
JOSÉ SOTO SAN MARTÍN

MIEMBROS DE LA COMISIÓN:
TBD
TBD

SANTIAGO DE CHILE
2026

RESUMEN DE LA TESIS PARA OPTAR AL GRADO
DE MAGÍSTER EN CIENCIA DE DATOS Y
MEMORIA PARA OPTAR AL TÍTULO PROFESIONAL
DE INGENIERO CIVIL MATEMÁTICO
POR: SEBASTIÁN GONZALO ACUÑA URZÚA
FECHA: 2026
PROF. GUÍA: EDUARDO GRAELLS-GARRIDO

**PREDICCIÓN DE ELECCIÓN DE RUTA EN REDES DE TRANSPORTE
PÚBLICO CON MACHINE LEARNING: EVIDENCIA DESDE DATOS
MASIVOS DEL SISTEMA RED DE SANTIAGO**

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

*Una frase de dedicatoria,
pueden ser dos líneas.*

Saludos

Agradecimientos

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Tabla de Contenido

1. Introducción	1
1.1. Objetivos e hipótesis de investigación	2
1.2. Estructura del documento	3
2. Revisión bibliográfica y estado del arte	4
3. Antecedentes teóricos	5
4. Metodología	6
5. Implementación de modelos	7
5.1. Modelo 1	7
5.1.1. Resultados	7
5.1.2. Análisis y discusión	7
5.2. Modelo 2	7
5.2.1. Resultados	7
5.2.2. Análisis y discusión	7
5.3. Modelo 3	7
5.3.1. Resultados	7
5.3.2. Análisis y discusión	7
6. Discusión general	8
7. Conclusiones	9
Bibliografía	10
Anexos	11
Anexo A. Análisis exploratorio de los datos	11

Capítulo 1

Introducción

El transporte público urbano constituye un pilar fundamental en la movilidad de las grandes ciudades. En Santiago de Chile, su relevancia es especialmente pronunciada: según datos del Censo 2024 realizado por el Instituto Nacional de Estadísticas (INE) [1], el 54 % de los viajes al trabajo se llevan a cabo en el transporte público (buses, metro o tren), en contraste con solo un 29 % que utiliza el automóvil particular, proporción que se mantiene como mayoría en 27 de las 34 comunas de la ciudad.

Durante las últimas décadas, Santiago ha desarrollado un sistema de transporte público integrado, actualmente conocido como Red Metropolitana de Movilidad, compuesto por buses urbanos, Metro y servicios ferroviarios. La magnitud de este sistema lo convierte en una infraestructura crítica para la ciudad: durante 2025, el sistema integrado superó los 1.370 millones de validaciones anuales, con 686 millones en buses, 662 millones en Metro y 22 millones en el tren Nos-Estación Central [2]. Asimismo, en abril de 2025 se registró un máximo diario superior a cinco millones de validaciones en el sistema integrado desde octubre de 2019 [3]. Estas cifras deben interpretarse como validaciones o transacciones y no necesariamente como viajes origen-destino completos, pero permiten dimensionar la escala operacional y social del sistema.

[CONTINUAR HABLANDO SOBRE ASPECTOS DE SANTIAGO Y CÓMO SU RED SE COMPARA (O NO) CON LA DE OTROS PAÍSES]

La integración tarifaria del sistema permite hasta dos transbordos dentro de una ventana de 120 minutos, de modo que los trayectos de los usuarios son en su mayoría viajes multietapa, en los que cada pasajero toma decisiones secuenciales sobre qué líneas utilizar, en qué paraderos transbordar y el momento para hacerlo. Estas decisiones constituyen lo que la literatura denomina como la “elección de ruta” en el transporte público.

[MENCIONAR CÓMO ESTO LE DA UN MATIZ EXTRA DE DIFICULTAD AL PROBLEMA PRODUCTO DE TODAS LAS POSIBLES RUTAS QUE UN USUARIO PUEDE TOMAR Y EL MANEJO DE TRANSFER NODES]

[HACER UN PUENTE ENTRE EL APPROACH HISTÓRICO CON MODELOS DE ELECCIÓN PARA CONECTARLO CON LA OPORTUNIDAD QUE OFRECE ML]

En paralelo al desarrollo de modelos conductuales tradicionales, el aumento en la disponibilidad de datos masivos ha impulsado el uso de métodos de aprendizaje automático en problemas de transporte. Estos métodos permiten capturar relaciones no lineales, interacciones complejas entre variables y patrones difíciles de especificar manualmente en una función de utilidad tradicional. En problemas de elección, esto abre una oportunidad para complementar los modelos de elección discreta con enfoques predictivos capaces de explotar

la granularidad de los datos pasivos.

La literatura reciente ha comenzado a explorar el uso de machine learning y deep learning para problemas de elección en transporte. No obstante, gran parte de estos esfuerzos se ha concentrado en elección de modo [CITA] o en elección de ruta para redes viales [CITA], mientras que la aplicación a elección de ruta en transporte público ha recibido menor atención. Lo más cercano corresponde a Marra y Corman [4], que propone un modelo de deep learning diseñado específicamente para elección de ruta en transporte público, destacando que estos modelos pueden estimar funciones de utilidad no lineales, incorporar variables no específicas de las alternativas y mejorar el desempeño predictivo respecto de modelos tradicionales como Path Size Logit, aunque a costa de nuevos desafíos de interpretabilidad.

Esta tensión entre capacidad predictiva e interpretabilidad es especialmente relevante para la presente investigación. Por una parte, el objetivo práctico de predecir qué ruta escogerá un usuario puede beneficiarse de modelos flexibles como árboles de decisión, random forests, gradient boosting, redes neuronales u otros métodos supervisados. Por otra parte, es de particular interés no limitarse a reportar métricas de desempeño predictivo, sino que también discutir qué información aportan los modelos sobre el comportamiento de los usuarios y cómo esos resultados pueden utilizarse en planificación o gestión del sistema. En ese sentido, los modelos de aprendizaje automático pueden entenderse no necesariamente como reemplazos de los modelos de elección discreta, sino como herramientas complementarias para explorar patrones, evaluar límites predictivos y comparar enfoques de modelación.

1.1. Objetivos e hipótesis de investigación

Esta tesis tiene como objetivo general desarrollar y evaluar modelos de machine learning para la predicción de probabilidades de elección de ruta en el sistema transporte público de Santiago, utilizando un conjunto de consideración construido de manera empírica a partir de datos históricos de las tarjetas Bip! en complemento con los datos GPS de los buses del sistema RED.

De este objetivo general se desprenden los siguientes objetivos específicos:

- i) Caracterizar el problema de elección de ruta en el sistema de transporte público de Santiago, identificando las particularidades de los datos disponibles y los principales desafíos para su modelación.
- ii) Construir una base de datos de viajes y alternativas de ruta adecuada para el entrenamiento y evaluación de modelos predictivos, considerando criterios de selección de usuarios, pares origen–destino, periodos horarios y atributos explicativos.
- iii) Desarrollar y comparar múltiples modelos de machine learning, entre ellos métodos de gradient boosting, random forest y [ALGÚN OTRO], para la predicción de la probabilidad de elección entre las alternativas del conjunto de consideración, utilizando como variables predictoras los atributos observables de cada ruta alternativa.
- iv) Analizar la importancia relativa de los atributos de ruta en la predicción, utilizando técnicas de interpretabilidad de modelos como SHAP values y otros equivalentes, con el fin de caracterizar las preferencias de los usuarios del sistema.

La hipótesis central de esta investigación es que los modelos de machine learning contemporáneos que transversalmente presentan mejor desempeño, entrenados sobre un conjunto de

consideración empíricamente construido a partir de datos históricos de tarjetas inteligentes, producirán predicciones de elección de ruta más precisas que los modelos estándar de elección discreta como Logit Multinomial (MNL) y Path Size Logit (PSL), y proveerán capacidades de interpretabilidad robustas donde los atributos más relevantes para la predicción reflejarán las preferencias conocidas de los usuarios, como la penalización por transbordo y la sensibilidad a los tiempos de espera que la literatura nacional e internacional ha identificado para este tipo de sistemas de transporte.

1.2. Estructura del documento

El presente documento se organiza de la siguiente manera. El capítulo 2 presenta la revisión de la literatura y el estado del arte en modelamiento de elección de ruta en el transporte público, con énfasis en técnicas de construcción del conjunto de consideración y los modelos estándar de utilidad implementados para este problema. El capítulo 3 describe los antecedentes teóricos, específicamente el contexto del sistema RED de Santiago y el conjunto de datos disponible. El capítulo 4 presenta la metodología de construcción del conjunto de consideración y la especificación de los modelos de elección discreta y de machine learning a utilizar. El capítulo 5 reporta los resultados obtenidos y las métricas de comparación de los modelos. Finalmente el capítulo 6 discute las implicancias de los hallazgos realizados y propone líneas de investigación futura.

Capítulo 2

Revisión bibliográfica y estado del arte

[WIP]

Capítulo 3

Antecedentes teóricos

Aquí se debe hablar de los datos que fueron utilizados para el proyecto, particularmente el uso de data más reciente (nov-2024 y abr-2025) para mayor compatibilidad con el GTFS que se encuentra en vigencia actualmente y así rescatar la mayor cantidad de rutas de transporte.

Capítulo 4

Metodología

[Esto es simplemente un punteo de las cosas que he ido realizando, para después revisar qué colocar y cómo hacerlo]

Se agregaron los datos en conjuntos semanales y se procesaron para dejarlos en formato parquet usando entre otros la librería duckdb, para posteriormente hacer preprocesamiento y feature engineering sobre los datos de manera sistemática con subconjuntos que no sobresaturen la memoria RAM por medio de la librería Polars.

Se implementa modelo de XGBoost con distintos enfoques. Primeramente un enfoque predictivo para poder hacer predicción de ruta. Para ello, se toma como variables independientes los hexágonos de origen y destino, junto con toda la información espacio-temporal, propósitos de viaje y otras variables exógenas, y utilizando como variable a predecir el par origen destino de paraderos, junto con la cantidad de etapas y paraderos intermedios.

En segundo lugar, se llevará a cabo un modelo XGBoost pero con una metodología learning to rank, que permita discernir y clasificar entre diferentes criterios relevantes que maximizan la utilidad de cada ruta disponible para el viajero a partir de los datos disponibles. Este modelo tiene mayormente fines explicativos que permitan entender mejor cómo los usuarios toman sus decisiones y los factores que mayor peso tienen en ese proceso.

Capítulo 5

Implementación de modelos

5.1. Modelo 1

5.1.1. Resultados

5.1.2. Análisis y discusión

5.2. Modelo 2

5.2.1. Resultados

5.2.2. Análisis y discusión

5.3. Modelo 3

5.3.1. Resultados

5.3.2. Análisis y discusión

Capítulo 6

Discusión general

Capítulo 7

Conclusiones

Bibliografía

- [1] Ministerio de Transportes y Telecomunicaciones, “Censo 2024: 54 % usa transporte público para ir a sus trabajos”. <https://mtt.gob.cl/censo-2024-54-usa-transporte-publico-para-ir-a-sus-trabajos/>, 2025. Accedido: 5 de mayo de 2026.
- [2] Red Metropolitana de Movilidad, “Usuarios de buses red aumentan las transacciones en 38 % desde 2022”, 2026, <https://www.red.cl/red-comunica/usuarios-de-buses-red-aumentan-las-transacciones-en-38-desde-2022/> (visitado el 2026-04-23).
- [3] Red Metropolitana de Movilidad, “Viajes en buses red alcanzan récord desde la pandemia”, 2025, <https://www.red.cl/red-comunica/viajes-en-buses-red-alcanzan-record-desde-la-pandemia/> (visitado el 2026-04-23).
- [4] Marra, A. D. y Corman, F., “Modelling route choice in public transport with deep learning”, *Transportation*, 2025, doi:10.1007/s11116-025-10597-7.

Anexos

A. Análisis exploratorio de los datos